


ScaleScape Lab

Case criado especificamente para a vaga de Desenvolvedor Back-End Pleno da Procob

Laboratorio autoral de scraping distribuido com FastAPI, RabbitMQ, Celery, Playwright, PostgreSQL, Alembic, Prometheus, Grafana, Next.js, Docker, VPS e CI/CD. O material nao representa parceria oficial com a Procob.



Resumo rapido: o projeto transforma os requisitos da vaga em uma demo navegavel e auditavel, com jobs reais, filas, workers, fontes publicas, target controlado, dashboard, metricas e documentacao tecnica.

1. O Que O Case Prova

O ScaleScape Lab foi feito para mostrar fit direto com a vaga da Procob: scraping em escala, sistemas distribuidos, mensageria, alto volume, retry, timeout, circuit breaker, observabilidade, Docker, Linux e diagnostico de bloqueios.

Requisito da vaga	Evidencia no projeto
Scraping em larga escala	API cria jobs, RabbitMQ distribui tarefas, Celery workers executam scraping e PostgreSQL persiste os itens.
Mensageria e pipeline distribuido	Filas scrape.jobs, scrape.retry e scrape.dead_letter, com workers stateless e agendamento a cada 6 horas.
Latencia e throughput	Benchmark controlado em tools/load_demo.py mede jobs/minuto, p50, p95, status, retries e itens coletados.
Retry, timeout e falhas	Retry/backoff, DLQ, circuit breaker por fonte, status auditavel por job e eventos operacionais.
Anti-bot, CAPTCHA e fingerprint	Simulador anti-bot controlado, reCAPTCHA de laboratorio, browser profile e debug artifacts.
Infra e observabilidade	Docker Compose, GitHub Actions, GHCR, VPS, Nginx, Prometheus, Grafana e RabbitMQ Management.

2. Scrapers Implementados

Fonte	Dificuldade / objetivo	Dados extraidos
fake-target	Site proprio com login, cookies, CAPTCHA de laboratorio e simulador anti-bot.	Itens paginados, categoria, origem, detalhe e data de extracao.
books-to-scrape	Fonte publica segura para provar parsing, detalhe e normalizacao.	Titulo, preco GBP, preco BRL, nota, descricao e link.
globo-home	Home publica da Globo, com noticias por categoria e enriquecimento em detalhe.	Categoria, titulo, resumo, link publico, imagem original e thumbnail salva.
betano-football	Site de apostas esportivas, mais dificil por protecoes anti-bot, sessoes e frontend dinamico.	Campeonato, jogo, data/hora, mercado, odds 1/X/2, bloqueios e horario da coleta.

Por Que Globo E Betano Ajudam Na Avaliacao

A Globo demonstra scraping real de conteudo publico com imagem, categoria e resumo sem depender apenas de massa fake. A Betano foi incluida como fonte mais dificil: um site de apostas com protecoes fortes, conteudo dinamico, modais e comportamento sensivel a rede/localizacao.

No caso Betano, o sistema usa Playwright, browser profile, sessao persistida, tentativa por API observada, fallback visual/DOM, proxy proprio via Tailscale e artefatos de debug. Quando o ambiente permite acesso autorizado, persiste odds auditaveis; quando ha bloqueio, registra 403, pagina vazia, redirect ou mudanca de markup sem loop agressivo.

3. Fluxo De Arquitetura

Usuario/Dashboard -> FastAPI -> PostgreSQL/job_events -> RabbitMQ -> Celery Worker -> Playwright Chromium -> fontes -> scraped_items -> Dashboard/Grafana/RabbitMQ Management.

O worker substitui os itens de cada job de forma idempotente, grava extracted_at, classifica falhas e atualiza metricas para observabilidade.

Falhas e controle operacional

- 403/429/timeout entram em retry com backoff quando a politica permite.
- Falhas esgotadas seguem para dead letter queue e alimentam diagnostico.
- Circuit breaker abre por fonte quando o padrao de falhas indica risco operacional.
- Proxy manager aplica cooldown e permite uso de proxy proprio/Tailscale para diagnostico de rede.

4. Anti-Bot Em Tom Responsavel

A vaga pede conhecimento em contorno de bloqueios, CAPTCHA, anti-bot e fingerprint. O case demonstra isso com simulador anti-bot controlado, reCAPTCHA de laboratorio, cookies/sessao, browser profile, diagnostico de 403/429, proxy proprio/Tailscale e debug artifacts.

O material nao ensina passo a passo para violar controles de terceiros. A proposta e mostrar engenharia responsavel: detectar bloqueio, registrar evidencias, reduzir agressividade, aplicar cooldown e operar apenas em ambientes autorizados.

5. Links De Demonstracao

Ambiente	UI	Dashboard	API Docs	Grafana	RabbitMQ
Dev	dev.scalescape.cledson.com.br	/dashboard	api-dev.../docs	grafana-dev...	rabbit-dev...
Producao	scalescape.cledson.com.br	/dashboard	api.../docs	grafana...	rabbit...

Grafana usa usuario admin; RabbitMQ Management usa scalescape_viewer. Senhas ficam somente em secrets de ambiente.

6. Roteiro De Demo Em 5 Minutos

- Abrir o dashboard e mostrar os cards de jobs, fontes ativas, scheduler e taxa recente.
- Disparar um scraping manual pelo botao da fonte desejada.
- Abrir Swagger e acompanhar GET /jobs/{id}.
- Abrir RabbitMQ para mostrar filas, consumers e mensagens.
- Abrir Grafana para mostrar metricas da API/worker.
- Na aba Globo, mostrar categoria, resumo, link e imagem persistida.
- Na aba Betano, explicar odds, protecao anti-bot, proxy/Tailscale e debug artifacts.
- Rodar ou apresentar tools/load_demo.py para falar de throughput, p50, p95 e retries.

7. Como Olhar O Codigo

Area	Caminho
API FastAPI	apps/api/app
Worker e scraping	apps/worker/app
Target-site e dashboard	apps/target_site/src
Infra e CI/CD	docker-compose.yml, compose.deploy.yml, .github/workflows
Benchmark	tools/load_demo.py
Fluxo tecnico	docs/fluxo-scraping.md

Fechamento: o case foi construido para evidenciar autonomia tecnica, perfil investigativo e capacidade de operar uma arquitetura de scraping com volume, falhas reais, mensageria, observabilidade e deploy automatizado.